

# **METODOLOGIA CAPM APLICADA À DEMANDA DE PASSAGEIROS DO TRANSPORTE AÉREO NOS ESTADOS BRASILEIROS**

Rodrigo Otávio de Araújo Ribeiro,

Steven Dutt Ross

Marcelo de Paula do Desterro

Na busca por métodos de análise que representem melhor a realidade da demanda de passageiros do transporte aéreo nos estados brasileiros, fez-se uso de alguns critérios desenvolvidos na metodologia CAPM (Capital Asset Pricing Model).

Nesta abordagem, pôde-se prever a demanda de passageiros do transporte aéreo nos estados com base no que ocorre na demanda total de passageiros no transporte aéreo.

Deste resultado, observou-se uma alta correlação entre os estados com maior densidade de passageiros transportados e a demanda agregada nacional.

Palavras-chave: CAPM, Previsão, Demanda

## **1. Introdução**

A motivação para este estudo veio da grande dificuldade de obtenção de estimativas mais acuradas de valores futuros do número de passageiros no transporte aéreo brasileiro. Utilizamos o método CAPM (Capital Asset Pricing Model) para fazer uma análise Top-down, isto é, obter as estimativas das demandas de passageiros do transporte aéreo nos estados com base na demanda agregada. No nosso caso, fizemos previsões para demanda de passageiros dos estados brasileiros para o mês de dezembro de 2000 com base

no que ocorreu no Brasil como um todo. Após as previsões, foi calculado o erro relativo obtido em cada um dos estados, tomando-se como base à demanda observada. Para isto, foram utilizados modelos de regressão linear simples (MRLS), tendo com variável explicada o retorno logarítmico do total de passageiros transportados por estado e como explicativa o retorno logarítmico do total de passageiros do Brasil. A finalidade da aplicação dos retornos compostos se deve a obtenção dos pressupostos necessários para aplicação do MRLS, normalidade, independência dos resíduos e homocedasticidade. Além disso, o citado retorno é uma medida livre de escala, o que permite comparar os dados.

Para estimação do valor futuro para número de passageiros do Brasil, foi utilizado o modelo X11Arima. Este modelo apresentou uma excelente aderência a série temporal do total de passageiros do país, gerando assim previsões mais coerentes com a realidade. Porém, vale salientar que podem ser adotados outros modelos na previsão da série dos dados agregados. A utilização do X11Arima deve-se apenas ao fato de que tal modelo apresentou melhores resultados que os demais.

Os dados referentes às séries de passageiros utilizadas foram obtidos no Anuário do Transporte Aéreo – Volume 1 – Departamento de Aviação Civil de 2001. O período contemplado no estudo foi de jan/97 a nov/00 para modelagem, e dez/00 para análise do erro relativo.

### **1.1. Motivação para previsão da demanda de passageiros**

A construção e manutenção de um aeroporto requerem uma grande quantidade de investimentos, tornando-se imprescindível um planejamento cuidadoso.

O transporte aéreo, em particular, é um setor extraordinariamente dinâmico e muito sensível a variações de uma enorme gama de fatores sócio-econômicos,

em consequência dos quais, as previsões de demanda apresentam, em alguns casos, um alto grau de incerteza (o atentado de 11 de setembro é um exemplo muito claro que ratifica tal afirmação).

Vale frisar que a precisão desejada nas estimativas varia muito conforme o objetivo da previsão. Estimativas de longo prazo sugerem erros maiores que as de curto prazo.

## **2. *Aplicação dos estudos de demanda do transporte aéreo***

Os estudos de demanda do transporte aéreo podem ser divididos em quatro abordagens principais:

- Dimensionamento de aeroportos e seus componentes;
- Estudos sobre políticas de planejamento e controle do sistema de aviação civil;
- Avaliação do nível de atividades do transporte aéreo.
- Dimensionamento e alocação da frota brasileira de aeronaves;

O planejamento de aeroportos tem como objetivo poder adequar a infraestrutura para suportar os futuros níveis de demanda que poderão ocorrer. Para esse tipo de estudo, são necessários, além de previsões de passageiros, modelos de simulação para tentar prever o impacto de determinadas obras ou modificações operacionais dentro dos aeroportos.

A avaliação do impacto de futuras políticas de planejamento e controle só é possível com a utilização de modelos de previsão de demanda.

Para as empresas aéreas, a essência do estudo da demanda está em prever a frota e a frequência de vôos. As previsões feitas para dimensionamento da frota são uma questão de sobrevivência para essas empresas. A maior parte da frota de aeronaves é adquirida por meio de leasing e estes contratos são em sua maioria indexados ao dólar. A desvalorização do real frente ao dólar contribuiu muito para a alarmante situação na qual encontra-se o mercado da aviação civil nos dias de hoje.

A aplicação prática do método contemplado neste trabalho está nas análises de curto prazo, o que se deve à provável mudança das inclinações das retas nos modelos. Sendo assim pode gerar bons resultados na previsão feita com o objetivo de alocação de frota e pessoal, além de uma estimativa satisfatória de curto prazo para aqueles estados que apresentaram bons resultados nos testes estatísticos de seus modelos.

### **3. Metodologia**

#### **3.1. Regressão Linear Simples**

Os retornos compostos do Pax utilizados nas regressões podem ser escritos da seguinte forma:

$$R_{i,t} = LN \left( \frac{Pax_{i,t}}{Pax_{i,t-1}} \right)$$

onde:

$Pax_{i,t}$ : Total de passageiros (embarcados + desembarcados) do i-ésimo estado ou Brasil, no mês t

$R_{i,t}$ : retorno composto do i-ésimo estado ou do Brasil, no mês t

Logo, os modelos podem ser expressos da seguinte forma:

$$\hat{R}_{it} = a_i + b_{it} \times R_t^{Brasil}$$

onde :

$a_i$  : estimador do intercepto do i-ésimo estado

$R_{it}$  : retorno composto do i-ésimo estado no mês t

$b_{it}$  : estimador da inclinação do referente ao i-ésimo estado em relação ao Brasil no mês t

$R_t^{Brasil}$  : retorno composto do Brasil no mês t

Vale ressaltar que os estimadores dos interceptos ( $a_i$ ) foram excluídos de todos os modelos ajustados, pois não foram considerados estatisticamente significativos para os modelos .

O objetivo das regressões é encontrar a inclinação entre os retornos compostos dos estados em relação aos retornos compostos do Brasil, isto é, os betas estimados de cada modelo de regressão linear para utilizar na fórmula do CAPM.

$$b_i = \frac{S_{i,Brasil}}{S_{Brasil}^2}$$

onde :

$b_i$  : estimador da inclinação do i-ésimo estado

$S_{i, \text{Brasil}}$  : estimador da correlação entre a série de retorno composto do i-ésimo estado e a série de retorno composto do Brasil

$S^2_{\text{Brasil}}$  : estimador da variância para a série de retorno composto do Brasil.

O método CAPM considera que as inclinações das retas estimadas nos modelos são consideradas constantes. Porém, é de primordial importância, estarmos sempre atentos para a modificação desses valores atrelada ao aumento da base de dados, isto é, saber até quando o modelo estará dando respostas coerentes. Tal problema, sem dúvida, será de vital importância em futuras aplicações do método de previsão aplicado neste trabalho.

### 3.2. Análises dos modelos

A tabela a seguir mostra os coeficientes de determinação, bem como as estimativas para as inclinações acompanhadas de seus respectivos p-valores :

Tabela –  $R^2$ , Inclinações ( $b_i$ ) e P-valores por estado

ESTADO	$R^2$	$b_i$	P-VALOR	ESTADO	$R^2$	$b_i$	P-VALOR
AC	0,35	1,21	8,07E-06	PB	0,51	1,66	1,82E-08
AL	0,69	1,85	3,92E-13	PE	0,84	1,32	4,04E-19
AM	0,30	1,02	5,69E-05	PI	0,26	1,47	1,73E-04
AP	0,53	1,58	5,72E-09	PR	0,56	1,47	1,73E-04
BA	0,62	1,10	5,17E-11	RJ	0,80	0,87	3,95E-17
CE	0,70	1,66	1,93E-13	RN	0,54	1,63	3,01E-09
DF	0,86	0,99	1,94E-20	RO	0,59	1,20	3,31E-10
ES	0,61	0,82	9,27E-11	RR	0,20	1,76	9,99E-04
GO	0,71	0,98	1,74E-13	RS	0,62	0,90	4,98E-11
MA	0,58	1,29	5,26E-10	SC	0,55	1,02	2,10E-09
MG	0,62	0,76	4,94E-11	SE	0,62	1,44	6,79E-11
MS	0,54	1,02	4,57E-09	SP	0,95	0,95	9,34E-31
MT	0,52	0,82	9,08E-09	TO	0,35	0,95	9,94E-06
PA	0,82	1,37	2,34E-18				

Note-se que os estados com maior participação no total agregado da demanda, tais como São Paulo, Rio de Janeiro, Distrito Federal e Minas Gerais, apresentaram valores para o  $R^2$  acima de 0,6. Porém, estados como Roraima, Acre e Amazonas, que não têm muita representatividade, não mostraram resultados tão bons.

O nível alfa, relativo ao erro de primeiro tipo adotado em todos os testes estatísticos deste trabalho foi de 0,05. Isto nos leva a rejeitar hipóteses nulas com p-valores abaixo de alfa.


Vale ressaltar que o modelo de regressão linear simples considera os resíduos estão distribuídos normalmente. Assim sendo, verificamos, através do teste de Kolmogorov Smirnov, que tal está hipótese não pode ser rejeitada em nenhum dos modelos, como se constata com base na tabela abaixo:

Tabela – Resultados do KS e P-valor por estado

ESTADO	KS	P-VALOR	ESTADO	KS	P-VALOR
AC	0,9538	0,3228	PB	0,5943	0,8717
AL	0,5439	0,9288	PE	0,8458	0,4717
AM	0,9883	0,2828	PI	1,3433	0,0542
AP	0,5353	0,9368	PR	0,539	0,933
BA	0,689	0,7294	RO	0,6804	0,7435
CE	0,9132	0,3747	RJ	0,9543	0,3222
DF	0,5215	0,9485	RN	0,595	0,8708
ES	0,6545	0,7849	RR	1,2454	0,0899
GO	0,7634	0,6047	RS	1,0291	0,2401
MA	0,8336	0,4906	SC	0,9739	0,299
MG	0,9144	0,3732	SE	0,6252	0,8293
MS	0,4804	0,9751	SP	0,6357	0,8138
MT	0,4675	0,9811	TO	0,6634	0,7709
PA	0,945	0,334			

Quanto à hipótese de homocedasticidade, os modelos apresentaram bons resultados, como pode ser visto no gráfico dos resíduos Vs. retorno composto do Brasil, do modelo de São Paulo. A heterocedasticidade é um problema relativo à não - constância da variância entre os resíduos em relação à variável explicativa.

Gráfico – Resíduos de SP Vs. Retorno Composto do Brasil



No gráfico acima, não é possível verificar tendência alguma dos resíduos em relação à variável explicativa. Isto nos leva a crer que a hipótese de heterocedasticidade não pode ser aceita. Nos demais modelos, os resultados foram semelhantes aos ocorridos em São Paulo, isto é, nenhum deles apresentou resíduos com tendências de crescimento ou decrescimento.

Como todos os modelos não apresentaram sinais de rejeição do método de regressão linear simples consideramos que os estimadores encontrados para as inclinações gozam de boas propriedades estatísticas, isto é, assumimos que as



hipóteses básicas para aplicação de modelos de regressão linear simples são atendidas.

A seguir, trataremos do modelo utilizado para a série agregada de passageiros.

### **3.3. X11 ARIMA**

Para a Previsão da demanda agregada de passageiros para dez/2000, utilizamos a previsão da demanda total do país na mesma data, tal estimativa foi obtida a partir do método X11-ARIMA. Este consiste em decompor a série temporal em diferentes partes e, a partir destas, prever o comportamento da série. Para ajustarmos a série de passageiros agregada, desmembramos seus componentes não observáveis da seguinte forma:

1-Tendência-Ciclo (T): Reflete a direção dos dados combinada com o ciclo (flutuação de curto prazo caracterizada pôr períodos alternados de contração e crescimento, relacionados, na maioria dos casos, com as oscilações da atividade econômica).

2-Variáveis Sazonais (S): São movimentos de curto prazo, que podem ser causados pelo clima, hábitos, feriados, etc.

3-Efeitos de calendário (K): São os efeitos considerados pelo número de dias trabalhados.

4-Irregular (I): São movimentos imprevistos relacionados com eventos distintos, já considerados.

A relação entre a série observada e seus componentes pode se dar da seguinte forma:

Aditiva

$$Y_t = T_t + S_t + K_t + I_t$$

Multiplicativa

$$Y_t = T_t \times S_t \times K_t \times I_t$$

O modelo encontrado para a previsão foi da forma multiplicativa, pois apresentou uma melhor aderência a série.

As séries mensais de passageiros apresentam muitos movimentos de curto prazo, chamados de sazonais. O tipo de passageiro que causa a sazonalidade dos dados é o turístico, pois o que viaja a trabalho é praticamente constante durante todo o ano. Na série observada, o mês de junho foi o que apresentou maior média durante o período. Isto se deve à coincidência entre o período de férias escolares, no meio do ano do calendário brasileiro com o período de férias dos turistas do hemisfério norte, que viajam muito para o Brasil nessa época do ano.

As flutuações sazonais podem ser subdivididas em quatro classes principais:

#### 1) Calendário

Algumas datas comemorativas, tais como Natal, Páscoa, Carnaval, afetam sensivelmente as séries de passageiros, já que, nestas datas comemorativas, as pessoas tendem a viajar mais. Como estamos trabalhando com séries mensais, o número de dias trabalhados de um mês pode gerar sazonalidade.

O Carnaval, por ser uma festa com data flutuante no decorrer dos anos, afeta nitidamente os dados mensais, causando sensível aumento da demanda no mês em que ocorre (fevereiro ou março).

## 2) Clima

Variações de temperatura, chuvas, nevoeiros e outras variáveis climáticas podem afetar diretamente a demanda de passageiros. Os aeroportos podem modificar datas de vôos ou até mesmo cancelá-los, devido situações climáticas adversas.

## 3) Expectativas

A expectativa de aumento de vendas de passagens, em épocas comemorativas pode gerar um aumento do número de vôos não-regulares. Muitas vezes companhias de turismo fretam aviões com antecedência na expectativa de venderem pacotes turísticos. Quando não obtêm o retorno esperado, dentro de um determinado prazo, fazem promoções, atraindo assim um maior número de passageiros.

## 4) Decisões baseadas em datas

Férias escolares, término do período universitário, bem como congressos e outros eventos podem influenciar a demanda de passageiros em um determinado aeroporto.

### **3.4. Procedimento X11**


O procedimento X11 foi desenvolvido pelo US Bureau of Census em 1965. É um refinamento do método de médias móveis, pois trabalha apenas com a decomposição da série nas suas componentes não-observáveis por meio de filtros de médias móveis, que conseguem captar com bastante eficácia, mudanças de curto prazo em séries temporais. Além disso, ele permite a análise de cada um dos estágios sucessivos do processo de ajuste sazonal.

O método X11 consiste dos seguintes passos :

- 1) Obtenção de estimativas preliminares da componente tendência aplicando uma média móvel centrada de 12 meses.
- 2) Obtenção de estimativas preliminares da componente sazonal através de médias móveis duplas (3X3) em cada mês, de forma a atingir fatores e correção sazonal a serem aplicados ao mês.
- 3) Substituição dos valores da componente sazonal com extrema irregularidade.
- 4) Recalcular os passos 1 e 2.
- 5) Ajustar a variação correspondente aos dias trabalhados (trading days) por regressão entre a componente irregular e as variáveis  $X_1, X_2, X_3, \dots, X_7$ , em que  $X_1$ =número de domingos ,...,  $X_7$ =número de sábados do mês. Em seguida recalcular o passo 2.
- 6) Ajustar a série pelo número de dias do mês, para que seja feita a atribuição de pesos diferentes para os meses.
- 7) Recalcular os passos 1 a 4 com o intuito de obter a série sazonalmente ajustada final.
- 8) Aplicação de uma média móvel centrada de 13 meses à série sazonalmente ajustada para obter a componente de tendência.
- 9) Testar a existência de sazonalidade estável e a existência da componente dias trabalhados.

A diferença entre os métodos X11 e X11 Arima consiste no fato de que o segundo, “estica” a série através de um modelo ARIMA com intuito de não perder informação, quando são feitas as médias móveis. Sendo assim, gera estimativas mais precisas que seu antecessor.

Gráfico - Ajuste da série de Pax Brasil



### 3.5. CAPM e Security Market Line

Para a aplicação do método CAPM ao transporte aéreo, foi feita a seguinte analogia com o mercado financeiro:

*Mercado Financeiro    Transporte Aéreo*

Ação	Estado
Preço de Ação	Pax do Estado
Retorno de Ação	Retorno do Pax
Carteira de Ação	Região

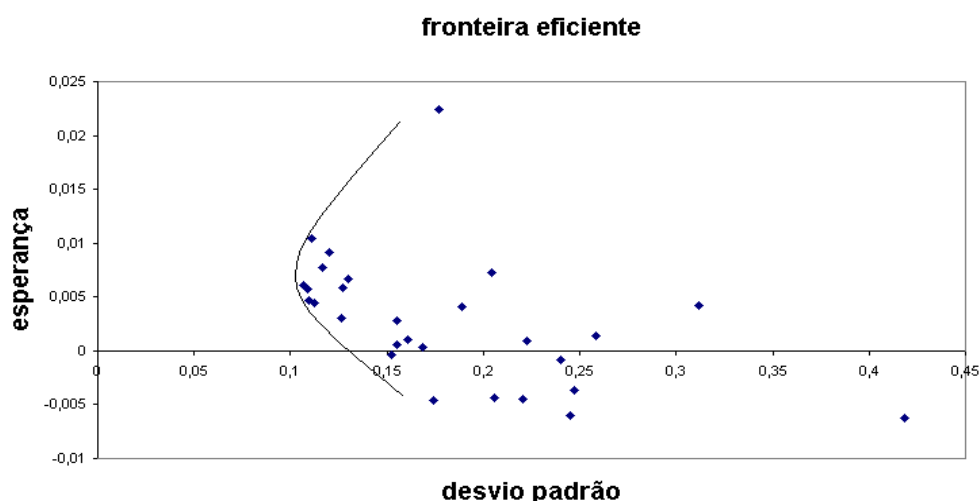
Mercado

Brasil

O objetivo da aplicação de algumas partes da metodologia CAPM está na possibilidade de prever a demanda de todos os estados com base em previsões do modelo robusto, estimado pelo método X11 ARIMA.

Com o intuito de encontrar a fronteira eficiente fizemos o gráfico entre o valor esperado dos retornos das séries e suas respectivas variâncias. Como podemos ver abaixo, obtivemos o formato que era esperado: uma “Bullet”.

Gráfico - Fronteira Eficiente



Observou-se que as regiões brasileiras não ficaram na fronteira eficiente. Vale frisar que não estamos buscando “carteiras de ações eficientes” em nossa aplicação, pois isto, não é possível devido à impossibilidade de alocarmos os estados brasileiros em regiões diferentes daquelas em que eles se encontram.

Uma importante observação feita, após a construção do gráfico, foi que o ponto das séries agregadas, isto é, do total do Brasil, se localizou na parte inferior da fronteira. Este fenômeno pode ser interpretado como a tendência do mercado de transporte aéreo em considerar que, quanto maior for a quantidade de passageiros transportados de uma determinada localidade, menor será a

variabilidade dessa série. Ao contrário do que ocorre normalmente no mercado financeiro, onde quanto maior o risco, maior é o retorno.

Após a construção do gráfico da fronteira, foi necessário encontrar o ponto de menor variância entre todas as séries de retorno, pois aplicamos o conceito do zero beta portfólio e assim realizar a construção da Security Market Line. Esta reta é o alicerce principal do método utilizado neste trabalho, pois é através dela que obtivemos as previsões. A Security Market Line pode ser expressa da seguinte forma:

$$R_{j,t+1} = Z + (R_{Brasil,t+1} - Z) \times b_j$$

onde:

$R_{jt+1}$  = previsão do retorno um passo à frente

Z = Zero beta portfólio

$R_{Brasil,t+1}$  = retorno composto do Brasil no instante t+1.

$b_i$  = inclinação na reta de regressão.

A previsões de demanda de passageiros nos estados foi para dezembro de 2000 foi feita com base na seguinte fórmula:

$$Pax_{t+1} = Pax_t \times \exp(R_{t+1})$$

onde :

$Pax_{t+1}$ : previsão de total de passageiros um passo à frente

$Pax_t$ : total de passageiros transportados no mês t

$R_{t+1}$ : previsão para o retorno um passo a frente

Os resultados obtidos juntamente com os erros relativos podem ser vistos na tabela seguinte:

Tabela - Resultados das previsões de retorno(Prev. Ret.), previsões de Pax  
( Prev. Pax) , Pax em dez/2000 e erro relativo por estado

ESTADO	Prev. Ret.	Prev. Pax.	Pax dez/2000	ERRO
AC	0,04196	18577	20254	8,28%
AL	0,06104	47518	53142	10,58%
AM	0,03656	111539	126192	11,61%
AP	0,05293	18753	19639	4,51%
BA	0,03869	324303	351704	7,79%
CE	0,05543	141536	169220	16,36%
DF	0,03560	445558	451066	1,22%
ES	0,03039	72738	70993	2,46%
GO	0,03529	74415	76444	2,65%
MA	0,04455	36763	39670	7,33%
MG	0,02856	272615	273906	0,47%
MS	0,03650	33031	39777	16,96%
MT	0,03052	42517	40107	6,01%
PA	0,04681	132275	137373	3,71%
PB	0,05541	20860	24800	15,89%
PE	0,04522	218582	222257	1,65%
PI	0,04968	19109	22940	16,70%
PR	0,02835	302812	288260	5,05%
RJ	0,03208	933732	938136	0,47%
RN	0,05450	60326	77947	22,61%
RO	0,04177	17792	25259	29,56%
RR	0,05829	7845	10791	27,30%
RS	0,03285	218540	227300	3,85%
SC	0,03637	135066	147951	8,71%
SE	0,04896	29189	24586	18,72%
SP	0,03427	2206210	2290490	3,68%
TO	0,03435	11210	10621	5,54%



#### **4. Conclusões**

A seguir, apresentamos a análise dos erros de previsão por região e, em cada região, comentamos os estados brasileiros e o  $R^2$  de cada estado.

Na região Sul, obtivemos excelentes resultados em todos os seus estados. O ajuste alcançado em Santa Catarina foi bom, e o poder de explicação foi de 55% ( $R^2$ ). O erro de previsão, neste caso, está abaixo de 10%, que é considerado normal em se tratando de transporte aéreo. O Paraná também obteve um erro de previsão inferior a 10% e um  $R^2$  de 56%, significa que 56% do retorno composto, de sua demanda de passageiros é explicada por uma única variável: o retorno composto do Brasil. Com um erro de previsão inferior a 5%, o Rio Grande do Sul obteve um ótimo resultado, com um  $R^2$  de 62%, que consideramos um bom poder de explicação para o modelo de regressão com uma só variável.

A metodologia CAPM obteve bons resultados na previsão de demanda dos estados com maior volume de passageiros transportados, principalmente na região Sudeste, com um erro de previsão menor que 5% em toda a região. Isto se deve à alta correlação positiva entre a variável explicativa (retorno composto do Brasil) e a variável explicada (retorno composto dos estados), sendo considerada a região de maior demanda de passageiros transportados do país. Em função disto, os modelos de regressão do Rio de Janeiro e São Paulo foram muito bem ajustados, gerando estimativas mais precisas, com grande poder de explicação do modelo. O  $R^2$  alcançado foi de 80%, no Rio de Janeiro, e 95% em São Paulo. Os estados com menor fluxo de passageiros da região tiveram modelos bem ajustados, com  $R^2$  de 62% em Minas Gerais e de 60% no Espírito Santo.

Na região Centro - Oeste, obtivemos bons resultados, mas em Mato Grosso do Sul houve um erro de previsão de 16,96% e um  $R^2$  de 53%, considerado bom, dado que esse estado é pouco significativo na demanda por transporte aéreo, representando somente 1% do transporte nacional. O Mato Grosso obteve uma

boa previsão, com um erro abaixo de 10% e um  $R^2$  de 52%. O Distrito Federal e Goiás alcançaram ótimos resultados, com um  $R^2$  de 86% (DF) e de 70% (GO), ou seja, um poder de explicação do modelo de 86% e 70%, respectivamente, e um erro menor que 5% do valor verdadeiro.

Na região Nordeste, a metodologia aplicada aponta que a previsão no Rio Grande do Norte obteve um erro de 22,61% e um coeficiente de determinação ( $R^2$ ) de 54%. Já no Ceará, Piauí, Paraíba, Alagoas e Sergipe, o erro foi menor que 20%. O  $R^2$ , nesses estados, foi de 70% (CE), 26% (PI), 50% (PB), 69% (AL), e 61% (SE), respectivamente. O  $R^2$  de Tocantins foi de 35%, do Maranhão de 58%, e na Bahia de 62%, sendo o erro menor que 10%. Pernambuco teve um boa revisão, com um erro menor que 5% e uma explicação de 83% no modelo.

A análise feita na região Norte constatou uma grande variação entre os erros relativos obtidos nos estados que a compõe. A Amazônia teve um erro de 11,61% e o poder de explicação de 29%. O Acre obteve um  $R^2$  de 35% e um erro de 8,28%. O Pará e o Amapá tiveram um erro menor que 5% e um  $R^2$  de 53% (AP) e de 82% (PA). Roraima e Rondônia, que alcançaram um  $R^2$  de 20% (RR) e de 59% (RO).

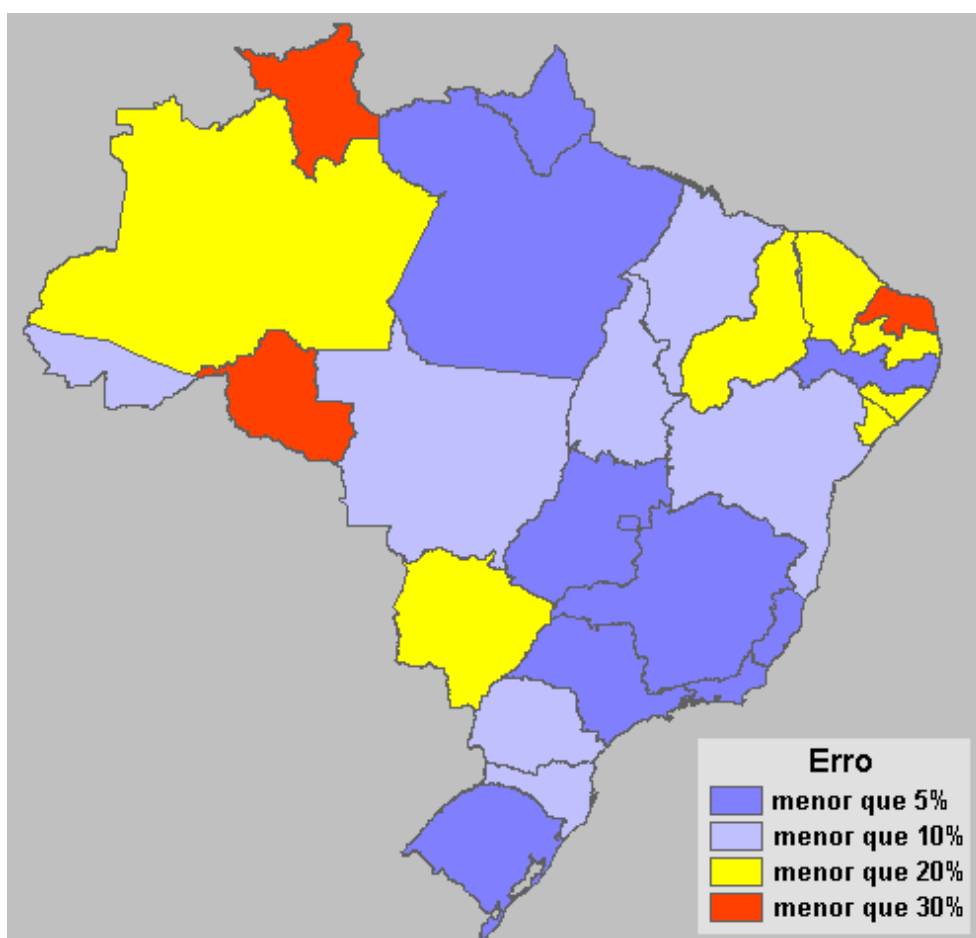
Vale lembrar que as regiões Sul, Sudeste e o DF representaram 77% da demanda de transporte aéreo do Brasil, em novembro de 2000, ao mesmo tempo que obtiveram os melhores resultados, enquanto os estados com erros maiores que 20% , a exemplo de Roraima, Rondônia e Rio Grande do Norte, representaram 1% na mesma data da demanda de transporte aéreo.

Os resultados obtidos com tal tipo de análise foram surpreendentes devido à inexistência da aplicação do CAPM no transporte aéreo. Porém, como já era esperado, nos estados de Roraima, Rondônia e no Rio Grande do Norte, que são menos significativos em termos de demanda nacional de passageiros

transportados, os resultados não foram tão satisfatórios, isto é, apresentaram maiores erros relativos.

No mapa abaixo, podemos visualizar os erros obtidos nas estimativas. É interessante verificar que, nas regiões com maior importância econômica, os erros foram menores.

Mapa - Erros encontrados nas previsões feitas para de dezembro de 2000



## 5. Referências

- HAUGEN, R. A. *Modern Investment Theory*. Englewood Cliffs: Prentice Hall, 2001.
- NETER, J., WASSERMAN, W. e KURTER, M.H. *Applied Linear Statistical Models*. Richard D. Irwin.1990.
- SHISKIN, J.,YOUNG,A .H., e MUSGRAVE, J.C. *The X-11 Variant of Census Method – 11 Seasonal Adjustment Program*. Technical Paper No.15, U.S. Bureau of the Census,1967.

### ABSTRACT

*In the search for methods of analysis to better represent the actual demand for passengers in air transportation in Brazilian states, some criteria have been developed within the CAPM (Capital Asset Pricing Model) methodology.*

*The passenger demand for air transportation in the states may be forecasted with this approach taking as base point the total demand for passengers in air transportation.*

*As from the results , it was observed a high correlation among the states with greater passenger transportation density and the gross national demand.*

*Key words: CAPM , forecast, demand*